

PROYECTO DE APRENDIZAJE NO SUPERVISADO

Nuestro proyecto utiliza el Mushroom Dataset que contiene información sobre características físicas de hongos para clasificarlos como comestibles o venenosos.

DATOS PRINCIPALES

- Dataset: 8,124 muestras de hongos
- Variables: 23 características categóricas y la variable objetivo: Class (Clasifica hongos como comestibles o venenosos)
- Técnicas aplicadas: Exploración de datos, codificación categórica, imputación de valores faltantes, PCA, K-Means Clustering, Random Forest.

EXPLORACION INICIAL

- Carga de datos: $8,124 \times 23$ variables categóricas
- Decodificación: Conversión de códigos (ej: 'e'→'edible', 'p'→'poisonous')
- Limpieza: Tratamiento de valores faltantes (principalmente en 'stalk-root')

PREPROCESAMIENTO

- One-Hot Encoding: Conversión de categóricas a numéricas
- Resultado: 117+ variables binarias
- Imputación: Estrategia de moda para valores faltantes

PCA

- Objetivo: Reducir complejidad manteniendo información
- Resultado: Con 10-15 componentes se mantiene el rendimiento óptimo
- Visualización: PCA 2D muestra dos grupos claramente separados

CLUSTERING


- Método del codo: Identificación del número óptimo de clusters
- Resultado óptimo: $k=4$ clusters
- Validación: Comparación con clasificación real



PROYECTO DE APRENDIZAJE NO SUPERVISADO


RESULTADOS A DETALLE:

PCA CON CLASES REALES



Esta gráfica muestra los datos proyectados en dos dimensiones principales (PCA) y coloreados según la clase real (class: comestible vs venenoso). Muestra la separabilidad natural entre hongos comestibles y venenosos.


K-MEANS



Esta gráfica muestra la inercia (suma de las distancias de los puntos a sus centros de cluster) en función del número de clusters (k). Se utiliza para determinar el número óptimo de clusters.


PROYECTO DE APRENDIZAJE NO SUPERVISADO

DISTRIBUCIÓN POR CLUSTERS



- Esta gráfica muestra la distribución de una variable categórica (por ejemplo, cap-color) dentro de cada cluster generado por K-Means.
- Ayuda a interpretar los clusters generados por K-Means.
- Muestra cómo las características categóricas están distribuidas dentro de cada cluster.

K.MEANS CLUSTERING EN PCA



- Clusters óptimos: 4 clusters identificados
- Calidad: Los clusters coinciden en gran medida con la clasificación real
- Interpretación: Cada cluster captura patrones específicos de características

PROYECTO DE APRENDIZAJE NO SUPERVISADO

RESULTADOS CLAVE Y METRICAS

Métrica	Valor	Comentario
Accuracy Random Forest	~100%	Clasificación casi perfecta
Reducción dimensional	90%+	De 117+ a 10-15 variables
Clusters identificados	4	Número óptimo por método del codo
Separabilidad	Excelente	Grupos claramente definidos

- Reducción dimensional exitosa: De 117+ variables a solo 10-15 componentes PCA
- Clustering efectivo: K-Means identificó patrones similares a la clasificación real
- Alta precisión: Random Forest alcanzó ~100% de accuracy
- Separabilidad clara: Los datos muestran dos grupos bien definidos

CONCLUSION

El análisis exploratorio demuestra que el dataset de hongos tiene patrones claros y es ideal para técnicas de clustering y clasificación. La combinación de PCA y K-Means proporciona una solución eficiente para identificar grupos naturales, mientras que Random Forest valida la precisión de los resultados.

GRUPO

Stephany Angeles Lizarraga
Michael Lopez

